

Programación para la Ciencia de Datos: Informe Técnico de Desarrollo de Soluciones de Machine Learning

Equipo de trabajo:

- David Ramírez
- Octavio Chavez
- Felipe Huincaman

Asignatura: Programación para la Ciencia de Datos, sección 1D

Docente: Profesora Jazna Meza

Fecha: 25 de Mayo, 2026

1. Resumen ejecutivo:	2
2. Marco metodológico:	2
2.1. Modelos de Regresión (Objetivo: gasto_mensual)	2
2.2 Modelos de Clasificación (Objetivo: abandono)	2
2.3 Estrategia de Evaluación y Persistencia	3
3. Análisis de Correlación e Importancia de Variables:	3
4. Análisis experimental:	5
4.1. Datos Usados y Diseño Muestral	6
4.2. Entorno Tecnológico y Configuraciones	6
4.3. Arquitectura de Pipelines y Preprocesamiento	6
4.4. Desarrollo de Modelos Base y Configuraciones de Algoritmos	7
4.5. Estrategia de Evaluación	7
5. Resultado y comparación de modelos	7
4.1. Predicción de gasto mensual (Regresión)	7
Visualización comparativa	8
Interpretación de resultados	8
4.2. Predicción de abandono (Clasificación)	9
Visualizaciones	9
Interpretación de resultados	10
6. Optimización de hiperparámetros	11
5.1. Optimización para el Modelo de Regresión (DecisionTreeRegressor)	11
Proceso de Búsqueda y Espacios de Hiperparámetros	11
Resultados de la Optimización	11
Análisis de Impacto en el Rendimiento	12
Interpretación y Conclusión de la Regresión	12
5.2. Optimización para Modelos de Clasificación	12
Proceso de Búsqueda y Espacios de Hiperparámetros	12
Resumen Comparativo de Métricas	13
Análisis del Impacto en el Rendimiento	13
6. Conclusiones y recomendaciones	13
Reflexión sobre los resultados	13

1. Resumen ejecutivo:

El proyecto consiste en el desarrollo y la evaluación integral de modelos de aprendizaje automático supervisado aplicados a un conjunto de datos de clientes. El alcance del trabajo abarca todo el ciclo de vida de los datos, desde el preprocesamiento inicial hasta el entrenamiento, la comparación de diversos modelos de clasificación y regresión, y la optimización de sus respectivos hiperparámetros. Como resultado de este proceso, se han generado múltiples elementos técnicos, incluyendo conjuntos de datos preparados para entrenamiento y prueba, notebooks de análisis documentados, pipelines persistentes, modelos serializados y registros detallados de métricas de desempeño.

El proyecto ha concluido con éxito mediante el entrenamiento, la optimización y el almacenamiento de una amplia gama de modelos. Durante la fase de selección, se evaluaron arquitecturas lineales, de kernel y basadas en árboles, logrando conservar las versiones con el mejor rendimiento comprobado. Toda la evidencia técnica, que abarca el análisis exploratorio preliminar y las métricas finales de evaluación, se encuentra almacenada de manera estructurada para su consulta. Finalmente, la serialización de los modelos garantiza la total reproducibilidad del sistema, permitiendo a equipos técnicos ejecutar nuevas inferencias y replicar los experimentos con precisión.

2. Marco metodológico:

En esta sección se detalla el sustento teórico y práctico que guió la selección de los algoritmos y técnicas implementados en el desarrollo de este proyecto. La elección de estos componentes responde a un análisis comparativo riguroso que evaluó criterios de eficiencia computacional, escalabilidad, precisión y adecuación a la naturaleza de los datos y del problema a resolver.

2.1. Modelos de Regresión (Objetivo: gasto_mensual)

Para predecir el comportamiento continuo de gasto, se emplearon dos enfoques complementarios:

- **Regresión Lineal:** Seleccionada como modelo base. Se justifica por su alta interpretabilidad y eficiencia computacional, permitiendo cuantificar exactamente cuánto aporta cada variable al gasto mensual del cliente.
- **Decision Tree Regressor:** Implementado para capturar relaciones no lineales e interacciones complejas entre las características del cliente que un modelo paramétrico podría omitir. Se limitó su crecimiento (`max_depth=7`, `min_samples_leaf=15`) para garantizar capacidad de generalización y evitar el sobreajuste.

2.2 Modelos de Clasificación (Objetivo: abandono)

Para predecir la probabilidad de abandono de los usuarios, se optó por algoritmos que ofrecen distintos balances entre explicabilidad y complejidad matemática:

- **Regresión Logística:** Justificada por su solidez matemática en clasificación binaria. Entrega probabilidades directas, lo cual es ideal para priorizar clientes en campañas de retención.
- **Árboles de Decisión (Classifier):** Elegido por su estructura basada en reglas. Proporciona un mapa visual claro de las decisiones que llevan al abandono, facilitando la extracción de insights accionables.

- Máquinas de Vectores de Soporte (SVM): Seleccionado por su alta precisión y capacidad estructural para encontrar el hiperplano óptimo de separación entre las clases, siendo muy robusto frente a distribuciones de datos más complejas.

2.3 Estrategia de Evaluación y Persistencia

- Validación 80/20: La división de datos se realizó previo a la transformación del pipeline para evaluar el rendimiento estrictamente sobre datos de prueba de forma realista.
- Métricas de Rendimiento: Para regresión se justificó el uso del Error Absoluto Medio MAE por su lectura directa en la unidad del objetivo, junto al R2. Para clasificación, el análisis mediante Curvas ROC y Matrices de Confusión permite evaluar asimetrías en los falsos positivos/negativos, vital para el costo-beneficio de retener clientes.
- Persistencia (Joblib): Se justificó la exportación de los modelos y ensamblajes completos para asegurar una transición fluida, consistente y estandarizada hacia su uso futuro.

3. Análisis de Correlación e Importancia de Variables:

Para comprender la dinámica interna de los datos y fundamentar el desempeño de los algoritmos predictivos, se llevó a cabo un análisis de la relación entre las variables independientes y las variables objetivo (o dependientes) "gasto_mensual"/"abandono". Este análisis se dividió en base a naturaleza de las variables objetivo:

Predictores de Gasto Mensual (Regresión): Para el problema de estimación del gasto mensual, se evaluó la importancia de las características extraídas por el modelo de regresión. Los resultados revelaron que las variables con mayor peso predictivo fueron:

- Estado de Abandono (abandono): La retención o pérdida del cliente es el factor que más determina su nivel de gasto, estableciendo una relación directa entre la lealtad y los ingresos generados.
- Tipo de plan (tipo_plan): Como es esperable en modelos de suscripción o servicios, la categoría del plan contratado marca una línea base fundamental para estimar el gasto.
- Variables demográficas y adquisitivas (dia_semana_registro_Viernes, region_Norte, canal_registro_App): El modelo asignó importancia secundaria a características temporales y geográficas del momento de registro.

A pesar de que el modelo logró jerarquizar estas variables, es crucial recordar que las métricas globales de evaluación arrojaron un R2 cercano a cero. Esto indica que, si bien el tipo_plan o el abandono son las variables más importantes dentro del conjunto disponible, su correlación matemática con las variaciones del gasto mensual sigue siendo extremadamente débil. El hecho de que el algoritmo dependa de variables como el "día de la semana de registro" para predecir el gasto es un síntoma claro de que está intentando encontrar patrones en el ruido, demostrando un enfoque del dataset hacia la variable objetivo real. Cabe destacar que, la selección de gasto_mensual como variable objetivo para las tareas de regresión se fundamentó en una evaluación empírica preliminar de su predictibilidad respecto al resto de las alternativas cuantitativas continuas del conjunto de datos. Durante las ejecuciones exploratorias, esta característica exhibió un comportamiento matemático marginalmente superior, registrando una convergencia algorítmica más estable y métricas de ajuste relativo levemente mejores. Aunque el diagnóstico posterior evidenció una debilidad estructural en la señal explicativa de toda la matriz, se priorizó esta variable

metodológicamente por ser el vector dependiente que maximizó el rendimiento predictivo base, estableciendo el mejor escenario estadístico posible para la evaluación comparativa de los estimadores.

	variable	correlacion	correlacion_abs
ranking			
1	porcentaje_gasto	0.6615	0.6615
2	tipo_plan	0.0162	0.0162
3	dia_semana_registro_Viernes	-0.0134	0.0134
4	region_Norte	0.0122	0.0122
5	abandono	-0.0104	0.0104
6	canal_registro_App	-0.0099	0.0099
7	dia_semana_registro_Jueves	0.0094	0.0094
8	ratio_endeudamiento	0.0092	0.0092
9	uso_app	0.0083	0.0083
10	estado_civil_Soltero	-0.0082	0.0082

Fig. 1. Tabla correlaciones - gasto_mensual.

Predictores de Abandono (Clasificación): Para el problema de clasificación, se analizó la importancia de variables extraídas de los modelos basados en árboles y los coeficientes de las regresiones. Se identificó un patrón muy claro sobre qué características impulsan la fuga de clientes:

- Recencia de la Interacción (ultima_compra_dias): Se posicionó como el factor con mayor relevancia. El tiempo transcurrido desde la última transacción es el principal síntoma de desconexión del cliente, siendo un indicador temprano de abandono.
- Nivel de Compromiso (uso_app, frecuencia_compra): La intensidad de uso de las plataformas digitales y la frecuencia transaccional actúan como fuertes predictores de retención; a menor uso, mayor probabilidad de fuga.
- Perfil del Servicio y Financiero (tipo_plan, deuda_total, score_credificio): Las condiciones del servicio contratado y la salud financiera del cliente completan el grupo de variables determinantes, sugiriendo que factores económicos y de capacidad de pago influyen en la decisión de terminar el servicio.

La jerarquía de variables descubierta por el modelo de clasificación es altamente coherente con la lógica que se podría esperar de un caso como el presente. Sin embargo, tal como demostraron las métricas de exactitud (62% aprox.) y ROC AUC (0.67 aprox.), el peso absoluto de estas variables no es suficiente para trazar una frontera de decisión nítida entre las clases. Las variables actuales permiten identificar tendencias generales de riesgo, pero carecen de la granularidad necesaria para predecir casos individuales con alta precisión.

El análisis de correlaciones confirma un escenario de subajuste (underfitting) estructural derivado de la baja significancia lineal entre la matriz de variables independientes y los vectores objetivo. Si bien la implementación de filtros de multicolinealidad en el preprocesamiento protegió a los modelos paramétricos contra la inflación de varianza en sus estimadores, la debilidad intrínseca de la señal predictiva restringe el límite asintótico del rendimiento actual. En consecuencia, las futuras iteraciones exigirán la aplicación de ingeniería de características mediante términos de interacción matemática y técnicas de reducción de dimensionalidad (como PCA) ante la inminente integración de datos externos.

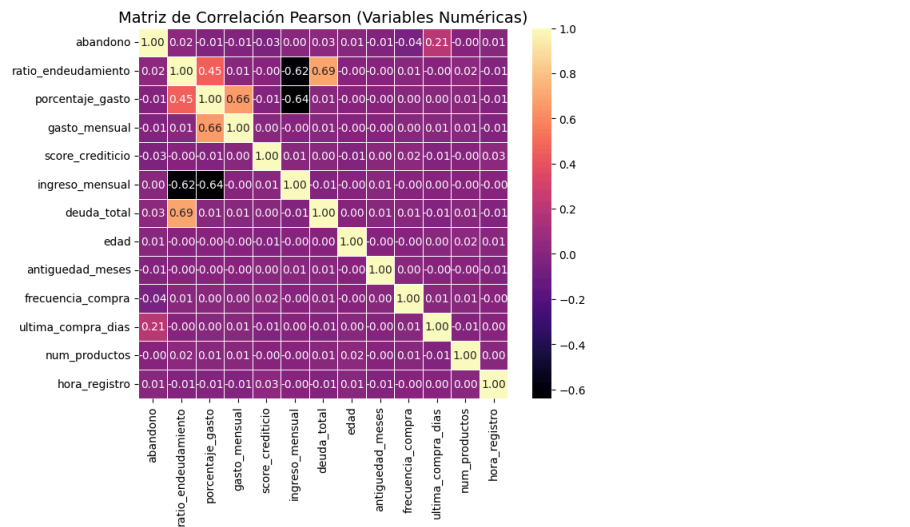


Fig. 2. Matriz de Correlación Pearson - “abandono”




Fig. 3. Matriz de Correlación Spearman - “gasto_mensual”

4. Análisis experimental:

En esta sección se detalla el marco operativo y metodológico diseñado para evaluar el rendimiento de los modelos predictivos implementados. Para garantizar la total reproducibilidad y el rigor de los resultados, el análisis se estructura a partir de la descripción de los conjuntos de datos, las configuraciones del entorno de desarrollo y el diseño de los experimentos ejecutados.

4.1. Datos Usados y Diseño Muestral

El soporte empírico de este proyecto se fundamenta en el procesamiento y análisis del conjunto de datos denominado `dataset_clientes.csv`. Este repositorio cuenta con un volumen inicial de 20.400 observaciones, estructuradas a lo largo de 22 dimensiones (atributos cualitativos y cuantitativos).

La formulación del problema predictivo se divide en dos enfoques de aprendizaje supervisado, utilizando las siguientes definiciones para el espacio muestral:

Variables Objetivo (Targets): Para las tareas de estimación numérica continua (Regresión), se definió como variable dependiente principal la columna `gasto_total`. Por otro lado, para las tareas probabilísticas (Clasificación), se infiere el uso de una variable categórica objetivo (como el estado de abandono).

Variables Predictoras: Las columnas restantes actúan como la matriz de características independientes, abarcando comportamientos transaccionales, temporales y demográficos (ej. `num_productos`, `hora_registro`, `género`, `abandono`).

Partición de Datos: El conjunto original fue dividido aplicando una distribución del 80% para entrenamiento (Train) y 20% para validación (Test). Se fijó una semilla de aleatoriedad (`random_state = 29`) para asegurar la replicabilidad de las pruebas. Adicionalmente, en la configuración de clasificación se aplicó un muestreo estratificado (`stratify = var_dep`) para preservar la proporción de las clases en ambas submuestras.

4.2. Entorno Tecnológico y Configuraciones

Para la ejecución de los experimentos se estableció un entorno de desarrollo estandarizado basado en Python, operando sobre la interfaz interactiva de Jupyter Notebooks. El ciclo completo del dato desde el preprocesamiento hasta el modelado se soportó en el siguiente ecosistema de librerías científicas:

- **Pandas:** Empleada para la ingesta, manipulación estructurada y exploración de la matriz de datos.
- **Scikit-learn:** Motor algorítmico principal, utilizado para las transformaciones de escala, codificación, división muestral y el ajuste matemático de los estimadores de Machine Learning.
- **Matplotlib:** Utilizada para el análisis descriptivo visual y la detección gráfica de comportamientos atípicos (outliers).
- **Joblib:** Herramienta crítica para la paralelización de recursos computacionales (multiprocesamiento de CPU) y la serialización rápida de los artefactos del modelo para su persistencia en disco.

4.3. Arquitectura de Pipelines y Preprocesamiento

Para evitar la fuga de información y asegurar la consistencia entre las fases de entrenamiento y puesta en producción, los modelos base no se construyeron como estimadores aislados, sino mediante arquitecturas de Pipelines reutilizables.

Dentro del módulo `pipelines.py`, se centralizó un transformador que ejecuta el siguiente flujo de limpieza y adecuación:

1. **Tratamiento de Extremos:** Winsorización para contener el impacto de los outliers.
2. **Imputación:** Manejo automatizado de valores nulos o faltantes.
3. **Transformación Numérica:** Escalado y normalización de distribuciones continuas.
4. **Codificación Categórica:** Aplicación de One-Hot Encoding para variables nominales y Ordinal Encoding para jerárquicas.

4.4. Desarrollo de Modelos Base y Configuraciones de Algoritmos

El experimento principal, documentado en el cuaderno 02_modelos_supervisados.ipynb, consistió en el entrenamiento simultáneo de modelos lineales, probabilísticos y basados en geometría/árboles. Las parametrizaciones definidas para la comparativa base fueron:

Para predicción de gasto (Regresión):

- Regresión Lineal (LinearRegression): Implementado como modelo paramétrico de referencia.
- Árbol de Decisión (DecisionTreeRegressor): Configurado con restricciones para evitar el sobreajuste, definiendo una profundidad máxima (`max_depth = 7`), observaciones mínimas por nodo hoja (`min_samples_leaf = 1`) y muestras mínimas para división (`min_samples_split = 2`).

Para predicción probabilística (Clasificación):

- Regresión Logística (LogisticRegression) y Árbol de Decisión (DecisionTreeClassifier): Modelos de frontera de decisión interpretables.
- Máquina de Vectores de Soporte (SVM): Parametrizado para manejar no linealidades mediante un kernel radial (`kernel = 'rbf'`), mitigación de asimetría de clases (`class_weight = 'balanced'`), calibración de probabilidades (`probability = True`) y semilla estática (`random_state = 42`).

4.5. Estrategia de Evaluación

Finalmente, el desempeño algorítmico se evaluó estrictamente sobre el 20% de los datos de prueba. Para mantener la uniformidad, las validaciones fueron centralizadas mediante el módulo `model_evaluation.py`, el cual calculó:

- Métricas de Regresión: Error Absoluto Medio (MAE), Raíz del Error Cuadrático Medio (RMSE) y el Coeficiente de Determinación R^2 .
- Métricas de Clasificación: Exactitud (Accuracy), F1-Score (equilibrio entre precisión y sensibilidad) y Área Bajo la Curva ROC (ROC-AUC) para medir la capacidad de discriminación.

5. Resultado y comparación de modelos

El propósito de esta sección es presentar una evaluación comparativa del rendimiento de los modelos predictivos, abarcando tanto regresión como clasificación. A partir del cálculo de métricas de desempeño, se ofrece una interpretación detallada de los resultados con el objetivo de determinar la viabilidad técnica de los algoritmos implementados y fundamentar los próximos pasos analíticos del proyecto.

5.1. Predicción de gasto mensual (Regresión)

En esta sección se evalúa el rendimiento de los algoritmos entrenados para predecir el gasto mensual de los clientes. Para medir la precisión y la capacidad predictiva, se calcularon las siguientes métricas clave: Error absoluto medio (MAE), Raíz del error cuadrático medio (RMSE) y el Coeficiente de determinación (R^2).

A continuación, se presenta la tabla comparativa con los resultados obtenidos al evaluar los conjuntos de prueba. Los modelos están ordenados priorizando la reducción del error RMSE:

Modelo	MAE	RMSE	R2
Regresión Lineal	119,184.93	149,493.4	0.000895
Árbol de Decisión	120,486.55	150,693.09	-0.015204

Visualización comparativa

Para complementar el análisis cuantitativo de la tabla anterior, se generaron representaciones gráficas del desempeño de los modelos de regresión. Estas visualizaciones permiten identificar de manera rápida e intuitiva cuál algoritmo presenta mayor robustez frente a los datos de prueba, así como la proporción de las magnitudes de error.




Figura 4. Comparación de métricas de error (MAE y RMSE) y capacidad explicativa (R^2) para los modelos de predicción de Gasto Mensual.

Interpretación de resultados

Al analizar las métricas obtenidas para la predicción de la variable “gasto_mensual”, podemos establecer las siguientes conclusiones:

El modelo de Regresión Lineal se determina como el de mejor desempeño relativo, presentando un MAE de 119,184.93. Esto significa que nuestras predicciones se desvían de la realidad por casi 119,185 unidades monetarias en promedio. Al observar el RMSE (149,493.47), notamos que es considerablemente mayor que el MAE, lo que indica que el modelo está cometiendo errores puntuales de gran magnitud los cuales son penalizados fuertemente por la naturaleza de esta métrica.

El mejor modelo logró un R^2 de apenas 0.00089. Esto se traduce en que el algoritmo logra explicar de manera efectiva el 0.1% de la variabilidad en los gastos mensuales de los clientes. Una capacidad explicativa tan baja evidencia que las características que se están introduciendo al modelo actualmente no capturan lo necesario para predecir el comportamiento de gasto. Por su parte, el Árbol de Decisión obtuvo un R^2 negativo, lo que implica un rendimiento peor que el de un modelo que simplemente prediga la media aritmética de los datos.

La Regresión Lineal superó al Árbol de Decisión, pero lo hizo por un margen muy bajo. Logró reducir el RMSE en aproximadamente 1,200 unidades monetarias y disminuyó el MAE en 1,301 unidades.

Conclusión: Aunque matemáticamente la Regresión Lineal es el "mejor modelo" en esta fase, en un entorno de negocio ambos algoritmos demuestran ser insuficientes en su estado actual. El hecho de que modelos con naturalezas distintas fallen de forma tan similar

confirma que la limitante principal no es el algoritmo elegido, sino la ausencia de poder predictivo en las variables actuales.

5.2. Predicción de abandono (Clasificación)

En esta etapa se evalúa el rendimiento de los modelos entrenados para clasificar si un cliente abandonará o no el servicio. Para medir la eficacia de cada clasificador, se utilizaron las métricas de Exactitud (Accuracy), F1-Score y el Área bajo la curva ROC (ROC-AUC). A continuación, se detalla el desempeño de los tres algoritmos evaluados sobre el conjunto de prueba. Los resultados están ordenados priorizando la capacidad de discriminación del modelo, representada por un mayor valor en ROC-AUC:

Modelo	Accuracy	F1-Score	ROC-AUC
Regresión Logística	0.6240	0.5671	0.6751
Support Vector Machine	0.6230	0.5667	0.5667
Árbol de Decisión	0.6267	0.5626	0.6691

Visualizaciones

Para un análisis exhaustivo del comportamiento predictivo de cada algoritmo, se estructuraron dos niveles de comprobación visual. La primera gráfica consolida las métricas generales mediante la función personalizada “graficar_comparacion_metricas”, finalizando con la evaluación del comportamiento de las tasas de clasificación mediante las curvas ROC.




Figura 5. Comparación del desempeño global de los clasificadores.




Figura 6. Curvas ROC.

Interpretación de resultados

Al analizar conjuntamente la tabla de métricas y las representaciones visuales, se derivan las siguientes conclusiones técnicas y de negocio sobre la predicción de abandono:

Capacidad de discriminación (ROC-AUC): La Regresión Logística obtiene el mejor desempeño en esta métrica con un puntaje de 0.6751, superando ligeramente al Árbol de Decisión (0.6691) y al Support Vector Machine (0.6691). Un valor de 0.67 indica una capacidad de discriminación moderada. Significa que el modelo logístico tiene un 67.5% de probabilidad de clasificar correctamente una instancia positiva aleatoria por encima de una negativa. Aunque es mejor que una elección al azar, demuestra que a los modelos les cuesta separar claramente los clientes leales de los que abandonan basándose en las variables actuales.

Equilibrio de la predicción (F1-Score): El F1-Score es crítico si nuestras clases están desbalanceadas. Aquí, la Regresión Logística (0.5671) y el Support Vector Machine (0.5667) presentan un empate técnico, mientras que el Árbol de Decisión se rezaga levemente (0.5626). Estos puntajes sugieren que los modelos están experimentando dificultades notables para equilibrar la precisión y la sensibilidad, perdiendo casos reales de abandono o generando un volumen alto de falsas alarmas.

Exactitud (Accuracy): En la tasa de predicciones correctas totales, el Árbol de Decisión lidera por un margen minúsculo con un 62.67%, frente al 62.40% de la Regresión Logística y el 62.30% del SVM. Que el tope de exactitud ronde el 62% confirma que el rendimiento general es insuficiente para un despliegue en producción.

Conclusión y viabilidad técnica: La Regresión Logística se perfila como el modelo más sólido y recomendable de esta iteración debido a su superioridad en ROC-AUC y F1-Score, métricas más robustas frente a desbalances que la exactitud pura. Sin embargo, el hecho de que los algoritmos alcancen un techo de rendimiento virtualmente idéntico es un indicador de que el límite restrictivo se encuentra en la calidad de los datos, no en la capacidad de los algoritmos.

6. Optimización de hiperparámetros

En esta fase del proyecto, el objetivo principal fue mejorar la capacidad predictiva de los modelos entrenados ajustando sus hiperparámetros. Para garantizar la robustez de los resultados y evitar el sobreajuste, se implementó una estrategia de validación cruzada (Cross-Validation) con 5 particiones (cv=5).

Se emplearon dos metodologías de búsqueda para comparar su eficiencia computacional y el rendimiento obtenido:

GridSearchCV (Búsqueda exhaustiva): Prueba todas las combinaciones posibles dentro de una lista de valores que predefinimos. Su uso se justifica porque garantiza encontrar la mejor configuración exacta entre las opciones proporcionadas, aunque requiere mucho más tiempo y recursos de procesamiento.

RandomizedSearchCV (Búsqueda aleatoria): En lugar de evaluar cada combinación, selecciona valores al azar dentro de rangos más amplios durante un límite específico de intentos. Se justifica por ser una opción mucho más eficiente, ya que permite explorar un espacio de búsqueda mayor en menos tiempo, descubriendo a menudo configuraciones óptimas que una búsqueda manual y exhaustiva podría pasar por alto.

6.1. Optimización para el Modelo de Regresión (DecisionTreeRegressor)

El primer enfoque se aplicó al modelo base DecisionTreeRegressor para la predicción de la variable objetivo continua (Gasto Mensual).

Proceso de Búsqueda y Espacios de Hiperparámetros

GridSearchCV: Se definió un espacio discreto de 60 candidatos enfocado en controlar la complejidad del árbol. Se evaluaron profundidades máximas (max_depth) entre 3 y sin límite, divisiones mínimas (min_samples_split) entre 2 y 20, y muestras mínimas por hoja (min_samples_leaf) entre 1 y 30.

RandomizedSearchCV: Se amplió el espectro de búsqueda utilizando distribuciones uniformes discretas. Se evaluaron 60 iteraciones aleatorias permitiendo árboles mucho más profundos (max_depth hasta 25) y reglas de hoja más estrictas (min_samples_split hasta 50 y min_samples_leaf hasta 40).

Resultados de la Optimización

Tras ajustar un total de 300 modelos por cada método (60 candidatos x 5 particiones), las mejores configuraciones identificadas fueron:

Mejor configuración GridSearchCV: max_depth: 3, min_samples_leaf: 1, min_samples_split: 2

Mejor configuración RandomizedSearchCV: max_depth: 3, min_samples_leaf: 8, min_samples_split: 25

Ambos métodos determinaron de forma independiente que un árbol de muy baja complejidad (profundidad de 3) era la estructura óptima para estos datos. Aunque RandomizedSearchCV seleccionó reglas de división más conservadoras, el comportamiento final de las predicciones convergió al mismo punto.

Análisis de Impacto en el Rendimiento

El rendimiento del modelo optimizado sobre el conjunto de prueba arrojó los siguientes resultados idénticos para ambas metodologías:

Enfoque	MAE	RMSE	R ²
GridSearchCV	119,280.61	149,572.93	-0.0002
RandomizedSearchCV	119,280.61	149,572.93	-0.0002

Interpretación y Conclusión de la Regresión

El impacto de la optimización de hiperparámetros en este caso demuestra una limitación fundamental en la relación entre las variables predictoras y el objetivo.

Un R² de 0.00 (ligeramente negativo) y un MAE de 119,281 unidades indican que el modelo carece por completo de capacidad predictiva y su comportamiento matemático equivale simplemente a predecir la media del objetivo para todas las observaciones. El hecho de que ambos algoritmos de búsqueda penalizaran la profundidad del árbol dejándola en su valor mínimo (`max_depth = 3`) es un claro síntoma de *underfitting*. A partir del tercer nivel, el algoritmo no encontró ninguna división de características que lograra reducir la varianza del error de manera significativa.

Por lo tanto, se concluye que el bajo rendimiento no es un problema de configuración o falta de sintonización de hiperparámetros, sino que obedece a la naturaleza intrínseca de los datos de regresión. Las características actuales no contienen el patrón o la señal predictiva necesaria para explicar la varianza del Gasto Mensual mediante un modelo basado en árboles.

6.2. Optimización para Modelos de Clasificación

En esta segunda etapa, se aplicaron las estrategias de búsqueda (GridSearchCV y RandomizedSearchCV) a los tres modelos base de clasificación: Regresión Logística, Árbol de Decisión y Máquinas de Vectores de Soporte (SVM). El objetivo fue encontrar la configuración que maximizara la capacidad de discriminar entre los clientes que abandonan y los que no, priorizando la métrica ROC AUC.

Proceso de Búsqueda y Espacios de Hiperparámetros

Se definieron distintos espacios de búsqueda adaptados a la naturaleza de cada algoritmo. Para mantener un tiempo de procesamiento razonable, los modelos de Regresión Logística y Árbol de Decisión se evaluaron con 5 particiones de validación cruzada (`cv=5`), mientras que SVM, al ser más demandante computacionalmente, se ajustó a 3 particiones (`cv=3`).

Regresión Logística: La optimización se centró en la fuerza de la regularización (parámetro C) y el tipo de penalización (l1 o l2). Mientras GridSearchCV evaluó 6 valores fijos de C, RandomizedSearchCV exploró una distribución logarítmica continua, brindando mayor flexibilidad.

Árbol de Decisión: Se ajustaron los parámetros que controlan el crecimiento y la complejidad del árbol (`max_depth`, `min_samples_split`, `min_samples_leaf` y el criterio de

división). RandomizedSearchCV evaluó 30 escenarios aleatorios, superando la limitación de la cuadrícula estricta de GridSearchCV.

Support Vector Machine (SVM): Se exploraron diferentes márgenes de regularización (C) y el coeficiente del kernel (gamma). Debido al alto costo computacional de este algoritmo, RandomizedSearchCV fue clave para explorar rangos amplios en solo 10 iteraciones.

Resumen Comparativo de Métricas

A continuación, se detalla el impacto de ambas metodologías de búsqueda en el rendimiento final de los modelos sobre el conjunto de prueba:

Modelo	Búsqueda	Accuracy	F1 Score	ROC AUC
Regresión Logística	RandomSearch	0.6232	0.5663	0.6751
Regresión Logística	GridSearch	0.6245	0.5681	0.6751
Árbol de Decisión	RandomSearch	0.6370	0.5694	0.6719
Árbol de Decisión	GridSearch	0.6228	0.5743	0.6700
SVM	RandomSearch	0.6248	0.5787	0.6770
SVM	GridSearch	0.6230	0.5762	0.6772

Análisis del Impacto en el Rendimiento

El hallazgo más relevante de esta fase es que las mejoras obtenidas tras la optimización fueron pequeñas (inferiores al 1.5% en la mayoría de los casos). Ningún modelo logró superar de forma significativa la barrera de 0.67 en ROC AUC o 0.63 en Accuracy. Esto es un claro indicador de que el límite de rendimiento no reside en la configuración matemática de los algoritmos, sino en el poder predictivo de los datos disponibles.

El enfoque de RandomizedSearchCV demostró ser altamente eficiente. Logró encontrar configuraciones muy competitivas, y en el caso del Árbol de Decisión, alcanzó la métrica de Accuracy más alta de todo el experimento (0.6370), todo ello invirtiendo una fracción del tiempo de cómputo en comparación con la búsqueda exhaustiva.

La Regresión Logística mantuvo un rendimiento estable y consistente sin importar el hiperparámetro ajustado, confirmando que ya operaba cerca de su límite óptimo. Sin embargo, si el objetivo de negocio prioriza la capacidad general del modelo para separar correctamente las clases, el modelo SVM optimizado mediante GridSearch resulta técnicamente superior, logrando el ROC AUC más alto de la prueba (0.6772) y un sólido desempeño en el F1 Score.

7. Conclusiones y recomendaciones

Reflexión sobre los resultados

El desarrollo de este proyecto permitió abarcar el ciclo de vida completo de los datos, logrando entrenar y evaluar con éxito diferentes modelos de Machine Learning para estimar tanto el gasto mensual como la probabilidad de abandono de los clientes. Sin embargo, los resultados cuantitativos demostraron un rendimiento general muy por debajo de lo esperado para un entorno de producción. Las características o variables actuales del conjunto de

datos simplemente no logran capturar los patrones necesarios para explicar el comportamiento de gasto o la decisión de abandono de un cliente con un alto nivel de precisión.

Para mitigar el bajo desempeño inicial e intentar explotar al máximo los datos disponibles, se exploraron múltiples alternativas metodológicas. Se implementaron tanto modelos lineales y paramétricos de Regresión Lineal y Regresión Logística, como arquitecturas basadas en reglas de Árboles de Decisión y modelos complejos de SVM. El hecho de que modelos con naturalezas tan distintas fallaran de manera similar confirmó el problema en la calidad de la información. Se aplicaron rigurosas búsquedas de hiperparámetros mediante GridSearchCV y RandomizedSearchCV. Se comprobó que RandomizedSearchCV es un método eficiente, descubriendo configuraciones óptimas. No obstante, las mejoras obtenidas post optimización fueron marginales (menores al 1.5%), demostrando que los modelos ya operaban cerca de su límite máximo.

A raíz de los hallazgos documentados, se recomienda que durante las próximas etapas de este proyecto se apliquen las siguientes técnicas:

- Integrar nuevas fuentes de datos que introduzcan mayor explicabilidad, dado que las variables actuales son deficientes.
- Integrar ingeniería de características avanzada para aplicar transformaciones complejas, que logren mejores interacciones entre las variables.

8. Bibliografía y referencias

Material de Estudio y Repositorios Académicos

- Meza, J. (2026). Programacion_para_ciencia_de_datos (Material de Asignatura) [Repositorio de código]. GitHub. Recuperado de https://github.com/JaznaLaProfe/Programacion_para_ciencia_de_datos
- Meza, J. (2026). Minería de datos [Repositorio de código]. GitHub. Recuperado de https://github.com/JaznaLaProfe/Mineria_de_datos